

Modele i Wnioskowanie Statystyczne  
Laboratorium 5

Sprawozdanie

Igor Markiewicz

### Zadanie 1

Model :

$$X \sim \mathcal{N}(\mu_X, \sigma^2)$$

$$Y \sim \mathcal{N}(\mu_Y, \sigma^2)$$

$$\bar{X} - \bar{Y} \sim \mathcal{N}(\mu_X - \mu_Y, \sigma^2(n^{-1} + m^{-1}))$$

a)

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\bar{X} \approx 0,146$$

$$\bar{Y} \approx 0,8884$$

$$\bar{X} - \bar{Y} = -0,7424$$

b)

$$s_i^2 = \frac{1}{n-1} \sum_{i=1}^n (\bar{x} - x_i)^2$$

$$s_X^2 \approx 1,155962$$

$$s_Y^2 \approx 0,9695833$$

$$s^2 = \frac{(n-1)s_X^2 + (m-1)s_Y^2}{m+n-2}$$

$$s^2 = 1,04946$$

c)  $s\sqrt{n^{-1} + m^{-1}} \approx 0,6872$

d) Dwustronny, ponieważ hipoteza zerowa i alternatywna się dopełniają w przeciwieństwie do testu jednostronnego.

e) Testowana hipoteza ma postać :

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2$$

A statystyka testowa :

$$T = \frac{\bar{X} - \bar{Y}}{s\sqrt{n^{-1} + m^{-1}}}$$

Wykorzystano funkcję *t.test* z parametrami *two.sided* = *TRUE* oraz *var.equal* = *TRUE*. W efekcie otrzymano *p-value*  $\approx 0,316$ .

f) Dla poziomu  $\alpha = 0,1$  nie mamy podstaw do odrzucenia hipotezy zerowej.

## Zadanie 2

a) Ze względu na brak informacji o równości wariancji :

$$X \sim \mathcal{N}(\mu_X, \sigma_X^2)$$

$$Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$$

postanowiono zastosować statystykę :

$$T = \frac{\bar{X} - \bar{Y}}{s}$$
$$s^2 = \frac{s_X^2}{n} + \frac{s_Y^2}{m}$$

dla testu :

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2$$

Statystyka  $T$  ma w przybliżeniu rozkład t – Studenta, z liczbą stopni swobody (po zaokrągleniu do liczby całkowitej) :

$$d \approx \frac{(s^2)^2}{\frac{(s_X^2/n)^2}{n-1} + \frac{(s_Y^2/m)^2}{m-1}}$$

Wykorzystano funkcję *t.test* z parametrami *two.sided* = *TRUE* oraz *var.equal* = *FALSE*. W efekcie otrzymano *p-value*  $\approx 0,0541$ , co oznacza że na poziomie istotności  $\alpha = 0,1$  możemy odrzucić hipotezę zerową na rzecz alternatywnej, zaś dla  $\alpha = 0,05$  nie mamy przeciwskażeń do przyjęcia hipotezy zerowej.

b) Wykonano test *Manna – Whitneya – Wilcoxona* (*test sumy rang Wilcoxona*) sprawdzający czy rozkłady dwóch zbiorów próbek różnią się o stałą wartość  $\mu$  (przyjętą tutaj jako 0) (m.in przy założeniu niezależności obserwacji, równej wariancji oraz równości rozkładów) :

$H_0$  – dystrybuanty rozkładów dla dwóch grup są przesunięte o 0

$H_1$  – dystrybuanty rozkładów dla dwóch grup są przesunięte wartość inną niż 0

Zastosowano funkcję *wilcox.test* z parametrem domyślnym *alternative* = "*two.sided*" oraz *paired* = *FALSE*, w efekcie czego otrzymano *p-value* = 0,063, a więc dla poziomu  $\alpha = 0,1$  możemy odrzucić hipotezę zerową na rzecz alternatywnej, zaś dla  $\alpha = 0,05$  nie ma przeciwskażeń do przyjęcia hipotezy zerowej.

c) Test nieparametryczny z podpunktu b) wydaje się być lepszym wyjściem, z racji na braku konieczności zakładania rozkładów normalnych, jednak posiada dużo dodatkowych obostrzeń do jego stosowania.

d) Wykorzystując bootstrap nieparametryczny, zliczono ilość sytuacji w której czas żywotności łożysk z pierwszego materiału był większy od czasu żywotności łożysk wykonanych z drugiego

materiału, a następnie podzielono tę liczbę przez liczbę próbkowań otrzymując estymatę szukanego prawdopodobieństwa ok. 0,750232.

### Zadanie 3

Model - dopasowanie funkcji liniowej w grupę punktów, tak aby minimalizowała błąd kwadratowy. Zakłada się że niepewności mają rozkład  $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$  :

$$y = \beta_0 + \beta_1 x$$


$$E(Y_i | X_i = x) = \beta_0 + \beta_1 x + \epsilon_i$$

$$\hat{\beta}_1 = \frac{\overline{XY} - \overline{X}\overline{Y}}{\overline{X^2} - \overline{X}^2}$$


$$\hat{\beta}_0 = \hat{Y} - \hat{\beta}_1 \overline{X}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$

Z racji na założenia fizyczne zjawiska, przyjęto  $\beta_0 = 0$ . Z takich samych względów dodano punkt pomiarowy  $[0, 0]$ .



Rys. 1: Regresja liniowa dla  $y \sim v$



Rys. 2: Regresja liniowa dla  $\sqrt{y} \sim v$

	$\hat{\beta}_1$
$y \sim v$	0,38390
$\sqrt{y} \sim v$	0,071199

Tab. 1: Wyliczone współczynnik  $\hat{\beta}_1$

Współczynniki dopasowania modelu do danych:

$$R^2 = \frac{\sum_{i=1}^n (y_i - f(x_i))^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$R_{adjusted}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

Gdzie  $n$  to liczebność próbki, a  $p$  liczba zmienny objaśniających.

	$R^2$	$R^2_{adjusted}$
$y \sim v$	0,918	0,9044
$\sqrt{y} \sim v$	0,9975	0,997

Tab. 2: Wyliczone współczynniki  $R^2$  oraz  $R^2_{adjusted}$

### **Wnioski :**

Możemy zauważyć że graficznie lepiej dopasowan jest zależność  $\sqrt{y} \sim v$ , co potwierdzają również współczynniki  $R^2$  oraz  $R^2_{adjusted}$  (im bliżej jedności tym lepiej model jest dopasowany).